

# PROJEKTNA SPECIFIKACIJA:

## Inteligentni sistem za igru „Ne ljuti se čovječe“

### 1. Identifikacija tima

#### Članovi tima:

- Luka Kešelj
- Lazar Nestorović
- Marko Mihajlović

### 2. Opis problema

#### 2.1 Motivacija

Igra „Ne ljuti se čovječe“ (Ludo) predstavlja deterministički sistem sa elementima slučajnosti (kocka) u kojem se donošenje odluka može precizno modelovati putem skupa logičkih pravila. Cilj ovog projekta je razvoj inteligentnog agenta koji implementira sistem zasnovan na pravilima (*rule-based system*) za autonomno donošenje odluka o pomjeranju figura, uvođenju novih figura u igru i optimizaciji kretanja u odnosu na protivnike.

#### 2.2 Definicija problema i ciljevi

Postojeće digitalne implementacije ove igre često se oslanjaju na statične algoritme i hardkodovanu logiku koja ne dopušta fleksibilnost ili lako proširenje. Glavni izazov koji ovaj projekat rješava je modelovanje dinamike igre kroz decoupling logike odlučivanja od samog koda, koristeći deklarativni pristup. Sistem omogućava:

- Fleksibilno ažuriranje strategija bez promjene osnovne strukture koda.
- Modelovanje kompleksnih interakcija između figura na tabli.
- Efikasnu evaluaciju stanja u realnom vremenu.

### 3. Metodologija (Osnovni nivo – Ocjena 8+)

#### 3.1 Ulazni podaci (Input)

Sistem prima trenutno stanje okruženja koje obuhvata:

- **Stanje table:** Pozicije svih aktivnih figura, broj figura u bazi i broj figura koje su završile igru.
- **Vrijednost kockice:** Generisana vrijednost u opsegu 1–6.
- **Identifikator aktivnog igrača:** Informacija o tome koji igrač je trenutno na potezu.

#### 3.2 Izlazni podaci (Output)

Rezultat obrade baze znanja je:

- **Odabrani potez:** Identifikacija konkretne figure koju treba pomjeriti ili akcija uvođenja nove figure na startnu poziciju.
- **Ažurirano stanje:** Transformacija trenutnog stanja u novo stanje nakon izvršene akcije.

#### 3.3 Baza znanja

Baza znanja je strukturirana kroz:

- **Činjenice (Facts):** Reprezentacija entiteta kao što su Figura(pozicija, vlasnik, status) i IshodKocke(vrijednost).
- **Pravila (Rules):** Logičke definicije za aktivaciju figura, kretanje po poljima i eliminaciju protivničkih figura.
- **Mehanizam aktivacije:** Primjena pravila vrši se metodom unaprijednog ulančavanja (*forward chaining*).

#### 3.4 Rezonovanje (Forward Chaining)

Sistem vrši ulančavanje kroz najmanje tri nivoa dubine:

1. **Nivo 1 (Inicijacija):** Provjera vrijednosti kocke (npr. ako je vrijednost 6, generiše se mogućnost izlaska iz baze).
2. **Nivo 2 (Validacija poteza):** Provjera dostupnosti polja za figure koje su već na tabli.

3. **Nivo 3 (Evaluacija konsekvenci):** Provjera da li odabrani potez rezultuje eliminacijom protivničke figure.

### 3.5 Akumulacione funkcije

Koriste se za agregaciju podataka o stanju igre, kao što su:

- Prebrojavanje aktivnih figura igrača na tabli.
- Određivanje prioriteta: Ako igrač ima manje od kritičnog broja aktivnih figura, sistem dodjeljuje veći prioritet pravilu za uvođenje nove figure u igru.

## 4. Napredna specifikacija (Ocjena 9–10)

### 4.1 Dodatna kompleksnost

Sistem se proširuje funkcionalnostima koje omogućavaju analizu toka igre, predviđanje rizika i adaptaciju strategije u zavisnosti od ponašanja protivnika.

### 4.2 Prošireni ulazi i izlazi

- **Istorija poteza:** Praćenje prethodnih stanja radi prepoznavanja obrazaca.
- **Strateške preporuke:** Generisanje obrazloženja zašto je određeni potez odabran sa aspekta rizika i dobiti.

### 4.3 Napredno rezonovanje (Backward Chaining)

Pored unaprijednog ulančavanja, uvodi se **unazadno ulančavanje** za verifikaciju strateških ciljeva. Sistem postavlja cilj (npr. "pobjeda u naredna tri poteza") i provjerava da li trenutno stanje i dostupna pravila podržavaju taj cilj, vršeći povratnu analizu kroz stablo odlučivanja.

### 4.4 Obrada kompleksnih događaja (CEP - Complex Event Processing)

Uvodi se mehanizam za detekciju događaja u realnom vremenu:

- **Detekcija prijetnje:** Identifikacija situacije u kojoj je figura igrača neposredno ugrožena od strane protivnika.

- **Detekcija prilike:** Prepoznavanje niza događaja (npr. više uzastopnih visokih vrijednosti na kocki) koji omogućavaju agresivniji pristup.
- **Promjena stanja ponašanja:** Prelazak iz defanzivnog u agresivni mod u zavisnosti od blizine protivničkih figura cilju.

#### 4.5 Napredna akumulacija

- Proračun prosječne udaljenosti figura od cilja.
- Evaluacija gustine protivničkih figura u kritičnim zonama table.

### 5. Zaključak

Predloženi sistem kombinuje paradigme **forward chaining-a** za operativno izvršavanje poteza, **backward chaining-a** za stratešku validaciju i **CEP-a** za adaptivno reagovanje na dinamiku igre. Ovakav pristup osigurava visoku inteligenciju agenta i omogućava lako proširenje logike igre bez potrebe za refaktorisanjem jezgra aplikacije.